



UNIVERSITÀ  
DELLA CALABRIA

DIPARTIMENTO DI **MATEMATICA**  
**E INFORMATICA**

# Report Progetto

## SciddicaT

227805 Spagnolo Domenico

## Sommario

1.	Abstract .....	3
2.	Introduction .....	3
3.	Parallel Implementations .....	5
•	Straightforward parallelization .....	5
•	Tiled parallelization with Halo Cells .....	6
•	Tiled parallelization without Halo Cells .....	6
•	MPI Parallelization .....	6
4.	Computational Performance .....	7
•	Monolithic.....	7
	<b>SpeedUp</b> .....	7
	<b>Plot</b> .....	7
	<b>Profiling</b> .....	8
•	Grid-Stride .....	8
	<b>SpeedUp</b> .....	9
	<b>Plot</b> .....	9
	<b>Profiling</b> .....	9
•	Tiles without halo.....	10
	<b>SpeedUp</b> .....	10
	<b>Plot</b> .....	11
	<b>Profiling</b> .....	11
•	Tiles with halo .....	12
	<b>SpeedUp</b> .....	12
	<b>Plot</b> .....	12
	<b>Profiling</b> .....	13
5.	Roofline Assessment .....	14
	<b>Specifiche JPDM2</b> .....	15
	<b>Calcolo Intensità aritmetica e applicazione del modello</b> .....	15
•	Monolithic.....	15
•	Grid-Stride .....	16
•	Tiles without halo.....	17
•	Tiles with halo .....	18
6.	Conclusions.....	19

# 1. Abstract

Obiettivo principale di questo report è lo sviluppo di diverse versioni parallelizzate di SciddicaT con la libreria CUDA.

## 2. Introduction

SciddicaT è un modello ad uso scientifico per la simulazione di flussi di fluidi non inerziali. Si basa sul *Cellular Automata Computational Paradigm* e sul *Minimization Algorithm of the Differences* (per il calcolo dei flussi tra celle adiacenti). Nonostante la sua semplicità, il modello è in grado di simulare frane non inerziali su superfici topografiche reali, come quella del Tessina in Italia avvenuta nel 1982, la cui configurazione iniziale viene anch'essa fornita insieme al codice sorgente dell'applicativo.

SciddicaT è definito come:

$$\text{SciddicaT} = \langle \mathbf{R}, \mathbf{X}, \mathbf{S}, \mathbf{P}, \sigma \rangle$$

**R**: è il dominio computazionale bidimensionale, suddiviso in celle di uguale dimensione;

**X**: è l'intorno di von Neumann (un pattern geometrico che identifica la cella centrale e un insieme di quattro celle poste nelle direzioni nord, ovest, est e sud, adiacenti a quella centrale). Le celle appartenenti all'intorno vengono etichettate con i seguenti valori: 0, 1, 2, 3, 4 mentre i flussi dalla cella centrale verso le quattro adiacenti sono identificate attraverso i seguenti indici: 0, 1, 2, 3.

Il diagramma sottostante mostra gli indici e le etichette di una cella e dei suoi dintorni:

```
Cell format: |flow_index:cell_label:(row_coord,col_coord)|
              cell_label in {0,1,2,3,4}: cell labels
              flow_index in {0,1,2,3}: outgoing flow indices
              (row_index,col_index): relative cells coordinates

              |0:1:(-1, 0)|
              |1:2:( 0,-1)|_0:( 0, 0)|2:3:( 0, 1)|
              |3:4:( 1, 0)|
```

**S**: è l'insieme degli stati della cella. È suddiviso nei seguenti sottostati:

- $S_z$ : è l'insieme dei valori che rappresentano l'altitudine topografica (es. quota s.l.m.);
- $S_h$ : è l'insieme dei valori che rappresentano lo spessore del fluido;
- $S_0^4$ : sono gli insiemi dei valori che rappresentano i deflussi dalla cella centrale alle quattro celle vicine adiacenti.

**P** =  $\{p_e, p_r\}$ : è l'insieme dei parametri che regolano la dinamica del modello. In particolare,  $p_e$  specifica lo spessore minimo al di sotto del quale il fluido non può defluire dalla cellula per effetto dell'aderenza, mentre  $p_r$  è il parametro del tasso di rilassamento, un fattore di smorzamento del deflusso.

$\sigma: S^5 \rightarrow S$  è la funzione di transizione cellulare deterministica. È composto da tre processi elementari, elencati di seguito nell'ordine in cui vengono applicati:

- $\sigma_0: S_0^4 \rightarrow S_0^4$ , imposta i deflussi dalla cella centrale alle celle adiacenti a zero.

- $\sigma_1: (S_z \times S_h)^5 \times p_\epsilon \times p_r \rightarrow S_0^4$ , calcola i flussi in uscita dalla cella centrale alle quattro celle adiacenti (nord, sud, ovest, est) applicando l'algoritmo di minimizzazione delle differenze
- $\sigma_2: S_h \times (S_0^4)^5 \rightarrow S_h$ , determina il valore dello spessore dei detriti all'interno della cella considerando lo scambio di massa nelle vicinanze della cella.

Oltre ai valori da assegnare ai parametri, che sono definiti nel codice sorgente (con  $p_\epsilon = 0.001$  e  $p_r = 0.5$ ), l'input al modello è rappresentato da tre file di testo in formato Ascii. Il primo (l'intestazione) definisce le dimensioni del dominio (numero di righe e colonne), le coordinate geografiche (della cella in basso a sinistra della griglia), la dimensione della cella e un valore no-data (usato per etichettare le celle con mancanza di informazioni). In realtà, vengono prese in considerazione solo le dimensioni del dominio e i valori no-data. I restanti file (mappe a griglia) rappresentano le informazioni riguardanti l'altitudine topografica e lo spessore del flusso per ogni dominio cellula.

La configurazione iniziale del sistema è definita come segue:

- Una mappa topografica viene letta da un file per inizializzare il sottostato  $S_z$ .
- Viene letta una mappa dello spessore di massa da un file per inizializzare il sottostato  $S_h$ ;
- I livelli del sottostato di deflusso sono inizializzati a zero ovunque.

Ad ogni iterazione, sono calcolati tre sottopassi di base, corrispondenti ai processi della funzione di transizione sopra descritti.

- Il kernel *sciddicaTResetFlows* corrisponde al processo elementare  $\sigma_0$ ;
- Il kernel *sciddicaTFlowsComputation* corrisponde al processo elementare  $\sigma_1$ ;
- Il kernel *sciddicaTWidthUpdate* corrisponde al processo elementare  $\sigma_2$ .




FIGURE 2: Initial and final configuration (after 4000 computational steps) of the system.

# The minimization algorithm

- **Convenzioni**

- 0=cella centrale; 1=Nord; 2=Est; 3=Ovest; 4=Sud
- $u(0)$  = parte inamovibile (strato roccioso) della cella centrale;  $m$  = parte mobile (detrito) della cella centrale
- $q_d(0,i)$  flusso della cella centrale verso l' $i$ -esima vicina
- $u(i)$  = quantità (inamovibili) delle celle vicine (quota + detrito)

- **Passi dell'algoritmo**



1. si calcola la media

$$a = (m + \sum_{i \in A} u(i)) / \#A$$

sull'insieme  $A$  delle celle non eliminate

2. se  $u(i) \geq a$ , la cella  $i$  è eliminata
3. i punti 1. e 2. sono iterati fino a quando nessuna cella è eliminata; il flusso dalla cella centrale verso l' $i$ -esima vicina non eliminata è:

$$q_d(0,i) = a - u(i)$$



## 3. Parallel Implementations

- Straightforward parallelization

- **Monolithic:** il kernel non ha modo di gestire il caso in cui il numero di elementi è maggiore del numero di thread disponibili.
- **Grid-Stride:** risolve il problema del kernel monolithic con i cicli. In particolare, vengono eseguiti più cicli sui dati. Il passo di un ciclo è  $blockDim.x * gridDim.x$  che è il numero totale di thread nella griglia. Quindi, se ci sono 1280 thread nella griglia, il thread-0 calcolerà gli elementi 0, 1280, 2560, ecc. Questo è il motivo per cui si chiama Grid-Stride. Usando un ciclo con stride (passo) uguale alla dimensione della griglia, ci assicuriamo la massima coalescenza della memoria, proprio come nella versione monolitica.


Vantaggi:

- ✓ **Scalabilità e riutilizzo dei thread.** Utilizzando un loop, è possibile supportare qualsiasi dimensione del problema anche se supera la dimensione massima della griglia supportata dal dispositivo CUDA. Inoltre, è possibile limitare il numero di blocchi utilizzati per ottimizzare le prestazioni.
- ✓ **Debugging.** Usando un loop invece di un kernel monolitico, è possibile passare all'elaborazione seriale avviando un blocco con un thread.
- ✓ **Portabilità e leggibilità.** Il codice del Grid-Stride loop è più simile al codice del ciclo sequenziale originale che al codice del kernel monolitico, rendendolo più chiaro per gli altri utenti. In effetti, è possibile scrivere facilmente una versione del kernel che si compila e viene eseguita come kernel CUDA parallelo sulla GPU o come loop sequenziale sulla CPU.

- Tiled parallelization with Halo Cells

Viene fatto uso della tecnica di Tiling, che consiste nel copiare pezzi (o meglio “piastrelle” quadrate) della matrice principale (memoria dichiarata **\_\_global\_\_**) su mini-matrici condivise (memoria dichiarata **\_\_shared\_\_**). In generale, la tecnica Tiling permette di ridurre gli accessi alla memoria globale (più lenta rispetto alla memoria condivisa) e di velocizzare le operazioni. Tutti i valori della matrice che “escono fuori” dalla “piastrella” (tile) vengono poste a 0 e sono chiamate celle Halo. Solo i thread che hanno entrambi gli indici più piccoli della larghezza della tile sono elaborati.

Di seguito, un esempio di Tiled 1D Convolution con Halo cells:



- Tiled parallelization without Halo Cells

Situazione simile alla precedente, ma questa volta non vengono considerate le celle Halo.

- MPI Parallelization

Con la funzione *updateHalo* vengono aggiornate le celle Halo. Nello specifico si sfruttano le funzioni base della libreria MPI, `mpi_Isend` e `mpi_Irecv`, per consentire la comunicazione NON bloccante tra thread e quindi l'aggiornamento.

Le funzioni *compute\_process* ricevono l'input dal processo server data, computano l'algoritmo ed eventualmente inviano indietro i chunk aggiornati al processo server data.

Prima di tutto, viene allocata sia sull'host che sulla GPU la memoria necessaria per memorizzare il chunk, incluse le halo. Ricevuto il chunk dal server data viene copiato nella GPU. In seguito viene allocata anche la memoria per i dati di output.


Le attività di calcolo sono suddivise in due fasi:

Fase 1.

- Tutti i processi di calcolo aggiornano le loro celle di confine (sia a sinistra che a destra).

Fase 2.

- Copia delle celle di confine aggiornate nell'host.
- Invio delle celle di confine ai processi adiacenti/ricezione delle celle di confine da processi adiacenti e memorizzazione nelle halo corrispondenti.
- Calcolo della parte interna del blocco.



## 4. Computational Performance

In questa sezione gli algoritmi sono analizzati dal punto di vista delle performance computazionali.

- Monolithic

	dimBlock(2,2,1) dimGrid(305,248,1)	dimBlock(4,4,1) dimGrid(153,124,1)	dimBlock(8,8,1) dimGrid(76,62,1)	dimBlock(16,16,1) dimGrid(38,31,1)	dimBlock(32,32,1) dimGrid(19,16,1)
Time [s]	10.45	5.13	3.65	3.94	4.27

SpeedUp

$$67.5/10.45 = 6.46$$

$$67.5/5.13 = 13.16$$


$$67.5/3.65 = 18.49$$

$$67.5/3.94 = 17.13$$

$$67.5/4.27 = 15.81$$

Tempo di esecuzione seriale = 67.5 s

Plot



Profiling

dimBlock(8,8,1)  
dimGrid(76,62,1)

```
==524863== nvprof is profiling process 524863, command: ./es1 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ../tessina_output_serial 4000
Elapsed time: 3.650000 [s]
Releasing memory...
==524863== Profiling application: ./es1 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ../tessina_output_serial 4000
==524863== Profiling result:
Type Time(%) Time Calls Avg Min Max Name
GPU activities: 41.40% 1.07206s 4000 268.02us 262.34us 342.79us sciddicaTFlowsComputation_Kernel(int, int, double, int*, int*, double*, double*, double*, double, double, int, int, int, int)
34.20% 885.76ms 4000 221.44us 211.68us 236.64us sciddicaTWidthUpdate_Kernel(int, int, double, int*, int*, double*, double*, double*, int, int, int, int)
24.40% 631.82ms 4000 157.95us 156.13us 456.93us sciddicaTResetFlows_Kernel(int, int, double, double*, int, int, int, int)
0.00% 15.296us 1 15.296us 15.296us 15.296us sciddicaTSimulationInit_Kernel(int, int, double*, double*, int, int, int, int)
API calls: 93.50% 2.70726s 12001 225.39us 9.5310us 466.67us cudaDeviceSynchronize
23.74% 923.95ms 12001 76.989us 70.429us 2.1647ms cudaLaunchKernel
6.62% 257.81ms 5 51.562ms 21.299us 256.36ms cudaMallocManaged
0.04% 1.7270ms 5 345.41us 28.002us 866.07us cudaFree
0.02% 763.23us 202 3.7780us 211ns 172.53us cuDeviceGetAttribute
0.01% 371.67us 2 185.83us 180.90us 190.77us cuDeviceTotalMem
0.00% 76.311us 2 38.155us 33.142us 43.169us cuDeviceGetName
0.00% 27.505us 2 13.752us 4.0790us 23.426us cuDeviceGetPCIBusId
0.00% 1.8580us 4 464ns 246ns 887ns cuDeviceGet
0.00% 1.690us 3 563ns 276ns 941ns cuDeviceGetCount
0.00% 830ns 2 415ns 348ns 482ns cuDeviceGetUuid

==524863== Unified Memory profiling result:
Device "GeForce GTX 980 (0)"
Count Avg Size Min Size Max Size Total Size Total Time Name
5 947.20KB 8.0000KB 1.5586MB 4.625000MB 1.745600ms Host To Device
70 102.23KB 4.0000KB 568.00KB 6.988281MB 2.818560ms Device To Host
Total CPU Page faults: 35
8ed78fa13180c12b4d8aee7ce6a362a ../tessina_output_serial
```

dimBlock(16,16,1)  
dimGrid(38,31,1)

```
==524933== nvprof is profiling process 524933, command: ./es1 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ../tessina_output_serial 4000
Elapsed time: 3.935000 [s]
Releasing memory...
==524933== Profiling application: ./es1 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ../tessina_output_serial 4000
==524933== Profiling result:
Type Time(%) Time Calls Avg Min Max Name
GPU activities: 45.67% 1.31917s 4000 329.79us 322.00us 445.92us sciddicaTFlowsComputation_Kernel(int, int, double, int*, int*, double*, double*, double*, double, double, int, int, int, int)
33.00% 955.52ms 4000 238.88us 224.58us 255.20us sciddicaTWidthUpdate_Kernel(int, int, double, int*, int*, double*, double*, double*, int, int, int, int)
21.26% 614.08ms 4000 153.52us 151.58us 435.07us sciddicaTResetFlows_Kernel(int, int, double, double*, int, int, int, int)
0.00% 17.344us 1 17.344us 17.344us 17.344us sciddicaTSimulationInit_Kernel(int, int, double*, double*, int, int, int, int)
API calls: 71.86% 3.00003s 12001 249.98us 9.5010us 455.17us cudaDeviceSynchronize
21.89% 914.05ms 12001 76.164us 68.770us 2.1510ms cudaLaunchKernel
6.17% 257.69ms 5 51.538ms 21.115us 256.22ms cudaMallocManaged
0.04% 1.7524ms 5 350.48us 26.559us 870.47us cudaFree
0.02% 736.37us 202 3.6450us 207ns 168.39us cuDeviceGetAttribute
0.01% 367.41us 2 183.71us 179.04us 188.37us cuDeviceTotalMem
0.00% 75.566us 2 37.783us 33.434us 42.132us cuDeviceGetName
0.00% 21.835us 2 10.917us 1.7720us 20.063us cuDeviceGetPCIBusId
0.00% 1.6870us 3 562ns 285ns 908ns cuDeviceGetCount
0.00% 1.5730us 4 393ns 238ns 833ns cuDeviceGet
0.00% 942ns 2 471ns 334ns 608ns cuDeviceGetUuid

==524933== Unified Memory profiling result:
Device "GeForce GTX 980 (0)"
Count Avg Size Min Size Max Size Total Size Total Time Name
5 947.20KB 8.0000KB 1.5586MB 4.625000MB 1.742000ms Host To Device
70 102.23KB 4.0000KB 568.00KB 6.988281MB 2.810048ms Device To Host
Total CPU Page faults: 35
8ed78fa13180c12b4d8aee7ce6a362a ../tessina_output_serial
```

dimBlock(32,32,1)  
dimGrid(19,16,1)

```
==525065== nvprof is profiling process 525065, command: ./es1 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ../tessina_output_serial 4000
Elapsed time: 4.273000 [s]
Releasing memory...
==525065== Profiling application: ./es1 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ../tessina_output_serial 4000
==525065== Profiling result:
Type Time(%) Time Calls Avg Min Max Name
GPU activities: 55.33% 1.92298s 4000 480.74us 475.68us 925.22us sciddicaTFlowsComputation_Kernel(int, int, double, int*, int*, double*, double*, double*, double, double, int, int, int, int)
27.26% 947.27ms 4000 236.82us 229.47us 276.55us sciddicaTWidthUpdate_Kernel(int, int, double, int*, int*, double*, double*, double*, int, int, int, int)
17.41% 605.10ms 4000 151.29us 149.41us 171.81us sciddicaTResetFlows_Kernel(int, int, double, double*, int, int, int, int)
0.00% 27.392us 1 27.392us 27.392us 27.392us sciddicaTSimulationInit_Kernel(int, int, double*, double*, int, int, int, int)
API calls: 79.40% 3.58478s 12001 298.71us 9.2570us 934.74us cudaDeviceSynchronize
14.81% 668.47ms 12001 55.700us 36.120us 2.0790ms cudaLaunchKernel
5.73% 258.75ms 5 51.750ms 32.884us 257.36ms cudaMallocManaged
0.04% 1.7332ms 5 346.63us 27.585us 885.97us cudaFree
0.02% 747.39us 202 3.6990us 210ns 165.15us cuDeviceGetAttribute
0.01% 378.17us 2 189.09us 181.99us 196.18us cuDeviceTotalMem
0.00% 107.81us 2 53.906us 33.392us 74.420us cuDeviceGetName
0.00% 21.366us 2 10.603us 3.1680us 18.198us cuDeviceGetPCIBusId
0.00% 2.1010us 4 525ns 261ns 809ns cuDeviceGet
0.00% 1.7680us 3 589ns 234ns 977ns cuDeviceGetCount
0.00% 1.2210us 2 610ns 439ns 782ns cuDeviceGetUuid

==525065== Unified Memory profiling result:
Device "GeForce GTX 980 (0)"
Count Avg Size Min Size Max Size Total Size Total Time Name
5 947.20KB 8.0000KB 1.5586MB 4.625000MB 1.742464ms Host To Device
70 102.23KB 4.0000KB 568.00KB 6.980281MB 2.809856ms Device To Host
Total CPU Page faults: 35
8ed78fa13180c12b4d8aee7ce6a362a ../tessina_output_serial
```

- Grid-Stride


	dimBlock(2,2,1) dimGrid(305,248,1)	dimBlock(4,4,1) dimGrid(153,124,1)	dimBlock(8,8,1) dimGrid(76,62,1)	dimBlock(16,16,1) dimGrid(38,31,1)	dimBlock(32,32,1) dimGrid(19,16,1)
Time [s]	10.66	5.24	3.25	3.53	4.18



## SpeedUp

$67.5/10.66 = 6.46$   
 $67.5/5.24 = 13.16$   
 $67.5/3.25 = 20.77$   
 $67.5/3.53 = 19.12$   
 $67.5/4.18 = 16.15$

## Plot



## Profiling

`dimBlock(8,8,1)`  
`dimGrid(76,62,1)`

```
--503701== NVPROF is profiling process 503701, command: ./es2 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ./tessina_output_serial 4000
Elapsed time: 3.254000 [s]
Releasing memory...
==503701== Profiling application: ./es2 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ./tessina_output_serial 4000
==503701== Profiling result:
Type      Time(%)      Time      Calls      Avg      Min      Max      Name
GPU activities:
42.50%    1.10444s    4000    276.11us    270.34us    303.33us    sciddicaTFlowComputation_Kernel(int, int, double, int*, int*, double*, double*, double*, double, double, int, int, int, int)
33.13%    860.88ms    4000    215.22us    202.21us    236.07us    sciddicaTWidthUpdate_Kernel(int, int, double, int*, int*, double*, double*, double*, int, int, int, int)
24.37%    633.42ms    4000    158.35us    156.55us    167.27us    sciddicaTResetFlows_Kernel(int, int, double, double*, int, int, int, int)
0.00%    16.384us    1    16.384us    16.384us    16.384us    sciddicaTSimulationInit_Kernel(int, int, double*, double*, int, int, int, int)
API calls:
77.33%    2.70638s    12001    225.51us    9.2570us    476.66us    cudaDeviceSynchronize
15.18%    531.08ms    12001    44.253us    42.009us    2.0822ms    cudaLaunchKernel
7.41%    259.35ms    5    51.869ms    20.734us    257.98ms    cudaMallocManaged
0.05%    1.6945ms    5    338.80us    27.329us    859.41us    cudaFree
0.02%    737.37us    202    3.6500us    211ns    169.12us    cuDeviceGetAttribute
0.01%    367.09us    2    183.54us    178.64us    188.45us    cuDeviceTotalMem
0.00%    74.343us    2    37.171us    32.289us    42.054us    cuDeviceGetName
0.00%    19.376us    2    9.6880us    1.9870us    17.389us    cuDeviceGetPCIBusId
0.00%    2.0640us    4    516ns    250ns    833ns    cuDeviceGet
0.00%    1.4920us    3    497ns    298ns    737ns    cuDeviceGetCount
0.00%    1.0440us    2    522ns    301ns    743ns    cuDeviceGetUuid

==503701== Unified Memory profiling result:
Device "GeForce GTX 980 (0)"
Count  Avg Size  Min Size  Max Size  Total Size  Total Time  Name
5      947.20KB  8.0000KB  1.5586MB  4.625000MB  1.745504ms  Host To Device
70     102.23KB  4.0000KB  568.00KB  6.988281MB  2.810016ms  Device To Host
Total CPU Page faults: 35
8ed78fal3180c12b4d8aee7ceba362a ./tessina_output_serial
```

dimBlock(16,16,1)  
dimGrid(38,31,1)

```
--525183== NvPROF is profiling process 525183, command: ./es2 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ./tessina_output_serial 4000
Elapsed time: 3.529000 [s]
Releasing memory...
--525183== Profiling application: ./es2 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ./tessina_output_serial 4000
--525183== Profiling result:
Type      Time(%)      Time      Calls      Avg      Min      Max      Name
GPU activities: 46.71% 1.34420s 4000 336.05us 326.85us 776.77us sciddicaFlowsComputation_Kernel(int, int, double, int*, int*, double*, double*, double*, double, double, int, int, int, int)
31.79% 914.73ms 4000 228.68us 213.09us 246.88us sciddicaWidthUpdate_Kernel(int, int, double, int*, int*, double*, double*, double*, int, int, int, int)
21.50% 618.56ms 4000 154.64us 152.83us 200.93us sciddicaResetFlows_Kernel(int, int, double, double*, int, int, int, int)
0.00% 18.240us 1 18.240us 18.240us 18.240us sciddicaSimulationInit_Kernel(int, int, double*, double*, int, int, int, int)
API calls: 79.08% 2.98400s 12001 248.65us 9.4110us 785.42us cudaDeviceSynchronize
14.02% 529.11ms 12001 44.088us 41.960us 2.0761ms cudaLaunchKernel
6.82% 257.34ms 5 51.468ms 24.147us 255.98ms cudaMallocManaged
0.05% 1.7095ms 5 341.91us 27.663us 862.45us cudaFree
0.02% 739.26us 202 3.6590us 210ns 168.35us cuDeviceGetAttribute
0.01% 369.24us 2 184.62us 180.41us 188.83us cuDeviceTotalMem
0.00% 75.771us 2 37.885us 33.025us 42.746us cuDeviceGetName
0.00% 20.436us 2 10.218us 1.8860us 18.550us cuDeviceGetPCIBusId
0.00% 1.5830us 3 527ns 247ns 803ns cuDeviceGetCount
0.00% 1.5100us 4 377ns 250ns 758ns cuDeviceGet
0.00% 1.0710us 2 535ns 346ns 725ns cuDeviceGetUuid

--525183== Unified Memory profiling result:
Device "GeForce GTX 980 (0)"
Count Avg Size Min Size Max Size Total Size Total Time Name
5 947.20KB 8.0000KB 1.5586MB 4.625000MB 1.748576ms Host To Device
70 102.23KB 4.0000KB 568.00KB 6.988281MB 2.809376ms Device To Host
Total CPU Page faults: 35
8ed78fa13180c12b4d8aee7ce6a362a ./tessina_output_serial
```

dimBlock(32,32,1)  
dimGrid(19,16,1)

```
--525232== NvPROF is profiling process 525232, command: ./es2 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ./tessina_output_serial 4000
Elapsed time: 4.177000 [s]
Releasing memory...
--525232== Profiling application: ./es2 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ./tessina_output_serial 4000
--525232== Profiling result:
Type      Time(%)      Time      Calls      Avg      Min      Max      Name
GPU activities: 55.53% 1.95350s 4000 488.37us 484.03us 739.75us sciddicaFlowsComputation_Kernel(int, int, double, int*, int*, double*, double*, double*, double, double, int, int, int, int)
27.28% 959.80ms 4000 239.95us 232.29us 408.19us sciddicaWidthUpdate_Kernel(int, int, double, int*, int*, double*, double*, double*, int, int, int, int)
17.19% 604.67ms 4000 151.17us 149.66us 168.22us sciddicaResetFlows_Kernel(int, int, double, double*, int, int, int, int)
0.00% 27.776us 1 27.776us 27.776us 27.776us sciddicaSimulationInit_Kernel(int, int, double*, double*, int, int, int, int)
API calls: 81.98% 3.62669s 12001 302.20us 9.3980us 749.58us cudaDeviceSynchronize
12.08% 534.21ms 12001 44.513us 42.523us 2.0745ms cudaLaunchKernel
5.88% 259.95ms 5 51.989ms 18.150us 258.58ms cudaMallocManaged
0.04% 1.7119ms 5 342.39us 26.977us 862.61us cudaFree
0.02% 745.03us 202 3.6880us 213ns 171.61us cuDeviceGetAttribute
0.01% 370.60us 2 185.30us 180.81us 189.79us cuDeviceTotalMem
0.00% 76.763us 2 38.381us 33.097us 43.666us cuDeviceGetName
0.00% 24.805us 2 12.402us 4.0380us 20.767us cuDeviceGetPCIBusId
0.00% 14.008us 4 3.5020us 252ns 12.911us cuDeviceGet
0.00% 1.7400us 3 580ns 267ns 953ns cuDeviceGetCount
0.00% 851ns 2 425ns 349ns 502ns cuDeviceGetUuid

--525232== Unified Memory profiling result:
Device "GeForce GTX 980 (0)"
Count Avg Size Min Size Max Size Total Size Total Time Name
5 947.20KB 8.0000KB 1.5586MB 4.625000MB 1.742912ms Host To Device
70 102.23KB 4.0000KB 568.00KB 6.988281MB 2.809376ms Device To Host
Total CPU Page faults: 35
8ed78fa13180c12b4d8aee7ce6a362a ./tessina_output_serial
```


- Tiles without halo

	tile_size = 2	tile_size = 5	tile_size = 10
Time [s]	12.26	3.99	3.79

SpeedUp

$67.5/12.26 = 5.51$   
 $67.5/3.99 = 16.92$   
 $67.5/3.79 = 17.81$

## Plot



## Profiling

Tiles\_size = 2

```
==523547== nvprof is profiling process 523547, command: ./es4 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ./tessina_output_serial 4000
Elapsed time: 12.257000 [s]
Releasing memory...
==523547== Profiling application: ./es4 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ./tessina_output_serial 4000
==523547== Profiling result:
Type      Time(%)      Time      Calls      Avg      Min      Max      Name
GPU activities: 68.53%  7.64714s  4000  1.9118ms  1.8797ms  2.4290ms  sciddicaFlowsComputation_Kernel(int, int, double, int*, int*, double*, double*, double*, double, double, int, int, int, int)
26.53%  2.96102s  4000  740.26us  731.97us  1.063ms  sciddicaWidthUpdate_Kernel(int, int, double, int*, int*, double*, double*, double*, int, int, int, int)
4.93%  550.66ms  4000  137.67us  136.16us  151.07us  sciddicaResetFlows_Kernel(int, int, double, double*, int, int, int, int)
0.00%  153.34us  1  153.34us  153.34us  153.34us  sciddicaSimulationInit_Kernel(int, int, double*, double*, int, int, int, int)
API calls: 90.13%  11.2626s  12001  938.47us  10.370us  2.4385ms  cudaDeviceSynchronize
7.79%  973.73ms  12001  81.137us  60.417us  2.1585ms  cudaLaunchKernel
2.05%  256.59ms  5  51.317ms  23.323us  255.14ms  cudaMallocManaged
0.01%  1.7262ms  5  345.24us  27.396us  809.04us  cudaFree
0.01%  738.04us  202  3.6530us  213ns  172.86us  cuDeviceGetAttribute
0.00%  365.20us  2  182.60us  177.90us  187.30us  cuDeviceTotalMem
0.00%  74.571us  2  37.285us  32.884us  41.687us  cuDeviceGetName
0.00%  20.069us  2  10.034us  1.6840us  18.385us  cuDeviceGetPCIBusId
0.00%  9.9820us  4  2.4950us  238ns  8.9020us  cuDeviceGet
0.00%  1.5610us  3  520ns  277ns  827ns  cuDeviceGetCount
0.00%  905ns  2  452ns  316ns  589ns  cuDeviceGetUuid

==523547== Unified Memory profiling result:
Device "GeForce GTX 980 (0)"
Count Avg Size Min Size Max Size Total Size Total Time Name
5 947.20KB 8.0000KB 1.5586MB 4.625000MB 1.746976ms Host To Device
70 102.23KB 4.0000KB 568.00KB 6.988281MB 2.809888ms Device To Host
Total CPU Page faults: 35
Bed78fa13180c12b4d8aacc7ce6a362a ./tessina_output_serial
```

Tiles\_size = 5

```
==523702== nvprof is profiling process 523702, command: ./es4 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ./tessina_output_serial 4000
Elapsed time: 3.990000 [s]
Releasing memory...
==523702== Profiling application: ./es4 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ./tessina_output_serial 4000
==523702== Profiling result:
Type      Time(%)      Time      Calls      Avg      Min      Max      Name
GPU activities: 51.99%  1.52172s  4000  380.43us  374.53us  815.04us  sciddicaFlowsComputation_Kernel(int, int, double, int*, int*, double*, double*, double*, double, double, int, int, int, int)
27.86%  815.30ms  4000  203.84us  193.22us  400.80us  sciddicaWidthUpdate_Kernel(int, int, double, int*, int*, double*, double*, double*, int, int, int, int)
20.15%  589.60ms  4000  147.40us  146.05us  176.06us  sciddicaResetFlows_Kernel(int, int, double, double*, int, int, int, int)
0.00%  28.544us  1  28.544us  28.544us  28.544us  sciddicaSimulationInit_Kernel(int, int, double*, double*, int, int, int, int)
API calls: 71.65%  3.03151s  12001  252.60us  9.1580us  824.82us  cudaDeviceSynchronize
22.17%  937.90ms  12001  78.151us  67.915us  2.1568ms  cudaLaunchKernel
6.12%  258.83ms  5  51.766ms  22.925us  257.38ms  cudaMallocManaged
0.04%  1.7235ms  5  344.70us  26.800us  876.69us  cudaFree
0.02%  744.72us  202  3.6860us  210ns  173.25us  cuDeviceGetAttribute
0.01%  368.71us  2  184.36us  180.09us  188.62us  cuDeviceTotalMem
0.00%  76.173us  2  38.086us  33.001us  43.172us  cuDeviceGetName
0.00%  21.763us  2  10.876us  3.320us  18.421us  cuDeviceGetPCIBusId
0.00%  1.6600us  3  553ns  295ns  878ns  cuDeviceGetCount
0.00%  1.6150us  4  403ns  243ns  857ns  cuDeviceGet
0.00%  924ns  2  462ns  319ns  605ns  cuDeviceGetUuid

==523702== Unified Memory profiling result:
Device "GeForce GTX 980 (0)"
Count Avg Size Min Size Max Size Total Size Total Time Name
5 947.20KB 8.0000KB 1.5586MB 4.625000MB 1.743744ms Host To Device
70 102.23KB 4.0000KB 568.00KB 6.988281MB 2.810208ms Device To Host
Total CPU Page faults: 35
Bed78fa13180c12b4d8aacc7ce6a362a ./tessina_output_serial
```

Tiles\_size = 10

```

==523850== NVPROF is profiling process 523850, command: ./es4 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ./tessina_output_serial 4000
Elapsed time: 3.794000 [s]
Releasing memory...
==523850== Profiling application: ./es4 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ./tessina_output_serial 4000
==523850== Profiling result:
Type      Time(%)      Time      Calls      Avg      Min      Max      Name
GPU activities: 51.95% 1.42785s    4000    356.96us  347.90us  787.04us  sciddicaTFlowsComputation_Kernel(int, int, double, int*, int*, double*, double*, double*, double, double, int, int, int, int)
                25.39% 697.92ms    4000    174.48us  169.06us  216.74us  sciddicaTWidthUpdate_Kernel(int, int, double, int*, int*, double*, double*, double*, int, int, int, int)
                22.65% 622.50ms    4000    155.62us  154.05us  461.19us  sciddicaTResetFlows_Kernel(int, int, double, double*, int, int, int, int)
                0.00% 18.432us      1    18.432us  18.432us  18.432us  sciddicaTSimulationInit_Kernel(int, int, double*, double*, int, int, int, int)
API calls:      70.94% 2.86119s   12001    238.41us  9.6150us  796.31us  cudaDeviceSynchronize
                22.60% 911.43ms   12001    75.946us  60.071us  2.1510ms  cudaLaunchKernel
                6.39% 257.55ms      5    51.510ms  18.902us  256.10ms  cudaMallocManaged
                0.04% 1.7205ms      5    344.11us  27.693us  872.27us  cudaFree
                0.02% 736.11us    202    3.6440us  211ns    171.01us  cuDeviceGetAttribute
                0.01% 365.64us      2    182.82us  179.40us  186.24us  cuDeviceTotalMem
                0.00% 75.737us      2    37.868us  33.052us  42.685us  cuDeviceGetName
                0.00% 22.517us      2    11.258us  3.7170us  18.800us  cuDeviceGetPCIBusId
                0.00% 1.9630us      3      521ns    276ns    833ns    cuDeviceGetCount
                0.00% 1.4720us      4      368ns    241ns    731ns    cuDeviceGet
                0.00% 941ns        2      478ns    325ns    616ns    cuDeviceGetUuid

==523850== Unified Memory profiling result:
Device "GeForce GTX 980 (0)"
Count Avg Size Min Size Max Size Total Size Total Time Name
5 947.20KB 8.0000KB 1.5586MB 4.625000MB 1.744096ms Host To Device
70 192.23KB 4.0000KB 568.00KB 6.988281MB 2.809792ms Device To Host
Total CPU Page faults: 35
Bed78fa13180c12b4d8aee7ceba362a ./tessina_output_serial

```


- Tiles with halo

	tile_size = 7 (block_width=9)	tile_size = 6 (block_width=8)	tile_size = 5 (block_width=7)	tile_size = 4 (block_width=6)	tile_size = 3 (block_width=5)	tile_size = 2 (block_width=4)
Time [s]	4.10	4.44	4.66	5.51	6.32	10.58

SpeedUp

$67.5/4.10 = 16.46$   
 $67.5/4.44 = 15.20$   
 $67.5/4.66 = 14.48$   
 $67.5/5.51 = 12.25$   
 $67.5/6.32 = 10.68$   
 $67.5/10.58 = 6.38$

Plot



## Profiling

mask\_size = 3  
tile\_size = 7  
block\_width = 9

```
==516877== NvPROF is profiling process 516877, command: ./es3 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ./tessina_output_serial 4000
Elapsed time: 4.092000 [s]
Releasing memory...
==516877== Profiling application: ./es3 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ./tessina_output_serial 4000
==516877== Profiling result:
   Type      Time(%)      Time      Calls      Avg      Min      Max      Name
GPU activities: 55.92% 1.91988s    4000  479.97us  472.13us  979.14us  sciddicaTFlowsComputation_Kernel(int, int, double, int*, int*, double*, double*, double, double, int, int, int, int)
                25.75% 884.10ms    4000  221.03us  212.51us  237.47us  sciddicaTWidthUpdate_Kernel(int, int, double, int*, int*, double*, double*, double*, int, int, int, int)
                18.33% 629.36ms    4000  157.34us  155.07us  427.71us  sciddicaTResetFlows_Kernel(int, int, double, double*, int, int, int, int)
                0.00% 21.248us     1  21.248us  21.248us  21.248us  sciddicaTSimulationInit_Kernel(int, int, double*, double*, int, int, int, int)
API calls:      81.69% 3.54044s  12001  295.01us  9.4230us  980.54us  cudaDeviceSynchronize
                12.36% 535.70ms  12001  44.638us  42.929us  2.0752ms  cudaLaunchKernel
                5.89% 255.14ms    5  51.029ms  19.023us  253.79ms  cudaMallocManaged
                0.04% 1.7154ms    5  343.08us  28.270us  867.07us  cudaFree
                0.02% 738.47us   202  3.6590us  216ns   169.93us  cuDeviceGetAttribute
                0.01% 363.98us    2  181.99us  179.04us  184.95us  cuDeviceTotalMem
                0.00% 85.975us    2  42.987us  32.875us  53.180us  cuDeviceGetName
                0.00% 20.972us    2  10.486us  3.7840us  17.180us  cuDeviceGetPCIBusId
                0.00% 1.9210us    3    640ns   259ns    914ns  cuDeviceGetCount
                0.00% 1.7690us    4    442ns   253ns    866ns  cuDeviceGet
                0.00% 854ns      2    427ns   346ns    508ns  cuDeviceGetUuid

==516877== Unified Memory profiling result:
Device "GeForce GTX 980 (0)"
   Count  Avg Size  Min Size  Max Size  Total Size  Total Time  Name
        5    947.20KB  8.0000KB  1.5580MB  4.625000MB  1.745792ms  Host To Device
       70   102.23KB  4.0000KB  568.00KB  6.988281MB  2.810016ms  Device To Host
Total CPU Page faults: 35
8ed78fa13180c12b4d8a8ec7ce6a362a ./tessina_output_serial
```

mask\_size = 3  
tile\_size = 6  
block\_width = 8

```
==516616== NvPROF is profiling process 516616, command: ./es3 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ./tessina_output_serial 4000
Elapsed time: 4.437000 [s]
Releasing memory...
==516616== Profiling application: ./es3 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ./tessina_output_serial 4000
==516616== Profiling result:
   Type      Time(%)      Time      Calls      Avg      Min      Max      Name
GPU activities: 55.85% 1.88732s    4000  471.83us  467.01us  970.66us  sciddicaTFlowsComputation_Kernel(int, int, double, int*, int*, double*, double*, double*, double, double, int, int, int, int)
                25.43% 859.58ms    4000  214.90us  208.90us  232.16us  sciddicaTWidthUpdate_Kernel(int, int, double, int*, int*, double*, double*, double*, int, int, int, int)
                18.72% 632.63ms    4000  158.16us  156.67us  180.64us  sciddicaTResetFlows_Kernel(int, int, double, double*, int, int, int, int)
                0.00% 20.800us    1  20.800us  20.800us  20.800us  sciddicaTSimulationInit_Kernel(int, int, double*, double*, int, int, int, int)
API calls:      74.74% 3.49677s  12001  291.37us  9.3809us  979.91us  cudaDeviceSynchronize
                19.68% 920.83ms  12001  76.729us  58.61us   2.1517ms  cudaLaunchKernel
                5.52% 258.27ms    5  51.655ms  19.464us  256.81ms  cudaMallocManaged
                0.04% 1.7022ms    5  340.44us  27.952us  859.63us  cudaFree
                0.02% 743.30us   202  3.6790us  214ns   172.84us  cuDeviceGetAttribute
                0.01% 368.38us    2  184.19us  179.97us  188.41us  cuDeviceTotalMem
                0.00% 77.762us    2  38.881us  32.803us  44.959us  cuDeviceGetName
                0.00% 19.690us    2  9.8450us  3.6900us  16.000us  cuDeviceGetPCIBusId
                0.00% 1.5790us    3    526ns   280ns    782ns  cuDeviceGetCount
                0.00% 1.5580us    4    389ns   246ns    880ns  cuDeviceGet
                0.00% 912ns      2   456ns   316ns   596ns  cuDeviceGetUuid

==516616== Unified Memory profiling result:
Device "GeForce GTX 980 (0)"
   Count  Avg Size  Min Size  Max Size  Total Size  Total Time  Name
        5    947.20KB  8.0000KB  1.5580MB  4.625000MB  1.744224ms  Host To Device
       70   102.23KB  4.0000KB  568.00KB  6.988281MB  2.810240ms  Device To Host
Total CPU Page faults: 35
8ed78fa13180c12b4d8a8ec7ce6a362a ./tessina_output_serial
```

mask\_size = 3  
tile\_size = 5  
block\_width = 7

```
==516384== NvPROF is profiling process 516384, command: ./es3 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ./tessina_output_serial 4000
Elapsed time: 4.664000 [s]
Releasing memory...
==516384== Profiling application: ./es3 ../data/tessina_header.txt ../data/tessina_dem.txt ../data/tessina_source.txt ./tessina_output_serial 4000
==516384== Profiling result:
   Type      Time(%)      Time      Calls      Avg      Min      Max      Name
GPU activities: 60.51% 2.42051s    4000  605.13us  596.54us  695.78us  sciddicaTFlowsComputation_Kernel(int, int, double, int*, int*, double*, double*, double*, double, double, int, int, int, int)
                24.73% 989.44ms    4000  247.36us  235.65us  403.62us  sciddicaTWidthUpdate_Kernel(int, int, double, int*, int*, double*, double*, double*, int, int, int, int)
                14.76% 590.40ms    4000  147.60us  145.57us  427.81us  sciddicaTResetFlows_Kernel(int, int, double, double*, int, int, int, int)
                0.00% 28.000us    1  28.000us  28.000us  28.000us  sciddicaTSimulationInit_Kernel(int, int, double*, double*, int, int, int, int)
API calls:      83.67% 4.10732s  12001  342.25us  9.6750us  704.94us  cudaDeviceSynchronize
                11.00% 540.19ms  12001  45.011us  42.625us  2.0628ms  cudaLaunchKernel
                5.26% 258.23ms    5  51.645ms  17.534us  256.86ms  cudaMallocManaged
                0.04% 1.7261ms    5  345.23us  26.911us  868.03us  cudaFree
                0.02% 745.06us   202  3.6880us  210ns   173.99us  cuDeviceGetAttribute
                0.01% 364.97us    2  182.48us  179.36us  185.60us  cuDeviceTotalMem
                0.00% 75.289us    2  37.644us  32.601us  42.688us  cuDeviceGetName
                0.00% 24.501us    2  12.250us  3.9450us  20.556us  cuDeviceGetPCIBusId
                0.00% 9.7060us    4  2.4260us  241ns    8.9470us  cuDeviceGet
                0.00% 1.4430us    3    481ns   262ns    730ns  cuDeviceGetCount
                0.00% 778ns      2   389ns   312ns   466ns  cuDeviceGetUuid

==516384== Unified Memory profiling result:
Device "GeForce GTX 980 (0)"
   Count  Avg Size  Min Size  Max Size  Total Size  Total Time  Name
        5    947.20KB  8.0000KB  1.5580MB  4.625000MB  1.743360ms  Host To Device
       70   102.23KB  4.0000KB  568.00KB  6.988281MB  2.809472ms  Device To Host
Total CPU Page faults: 35
8ed78fa13180c12b4d8a8ec7ce6a362a ./tessina_output_serial
```

## 5. Roofline Assessment

Il modello Roofline è un modello di performance visuale che consente in maniera intuitiva di stimare le performance di un dato kernel computazionale o di una applicazione che esegue su architetture di calcolo di tipo multi-core mostrando graficamente le limitazioni inerenti all'hardware usato e le potenziali ottimizzazioni da poter applicare, nonché la priorità con cui esse necessitano di essere applicate.

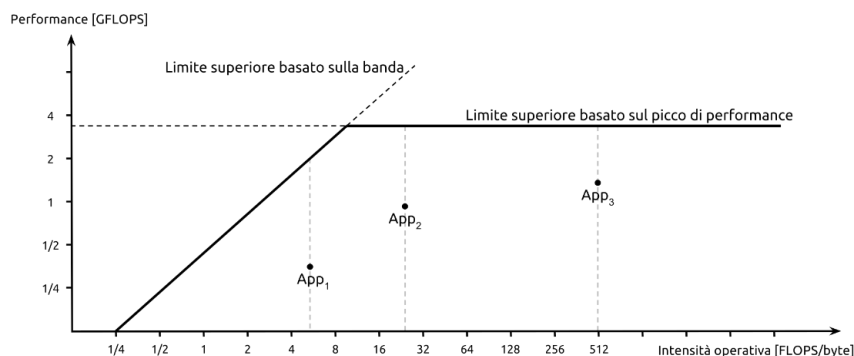
Parametri modello:

- Un parametro tenuto in considerazione dal modello è l'intensità delle comunicazioni, ciò che viene valutato qui è la **larghezza di banda della memoria**, misurata in Gigabyte per secondo (miliardi di byte trasferiti al secondo). Il motivo per cui viene valutato questo aspetto è dovuto al fatto che la memoria ha una grande incidenza sul tempo di risoluzione di un algoritmo poiché le unità aritmetiche devono operare su dati scritti in memoria. Per cui si ricorre a meccanismi di caching per rendere la fase di lettura e scrittura dei dati da e per la memoria più rapidi. Inoltre, anche le ottimizzazioni dal punto di vista software possono aiutare ad evitare dei cache miss quindi a minimizzare le comunicazioni inutili da e verso le memorie.
- Altro aspetto è la **locazione della memoria**: in caso di memoria distribuite più esse saranno numerose, maggiore è la probabilità di un aumento delle comunicazioni; per questo è necessario applicare le tecniche per favorire la località dei dati.

Il modello Roofline consiste in un grafico/tabella che considera le caratteristiche descritte precedentemente, e il fulcro di questo modello è quello di mettere in relazione i GFLOPs con i GByte/s con una quantità chiamata intensità aritmetica (in letteratura anche definita col nome di Computational Intensity). L'intensità aritmetica è la stima del numero di richieste che un software effettua alla memoria, o meglio è il numero di operazioni in virgola mobile per byte di memoria a cui è richiesto l'accesso alla memoria.

Arithmetic Intensity, Algorithm dependent      Bandwidth, HW dependent

$$FLOPS = \frac{\#FLOP}{\text{time (Sec)}} = \frac{\#FLOP}{\text{Byte}} \times \frac{\text{Byte}}{\text{Sec}}$$
$$FLOPS = AI \times BW$$



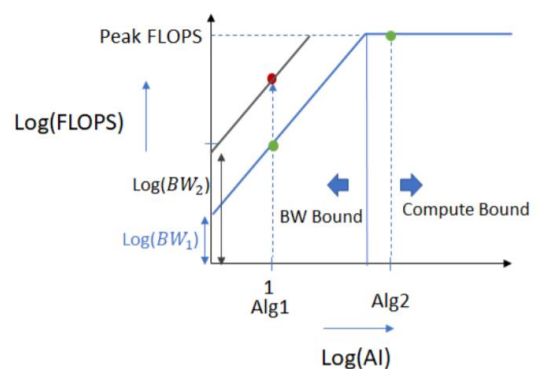
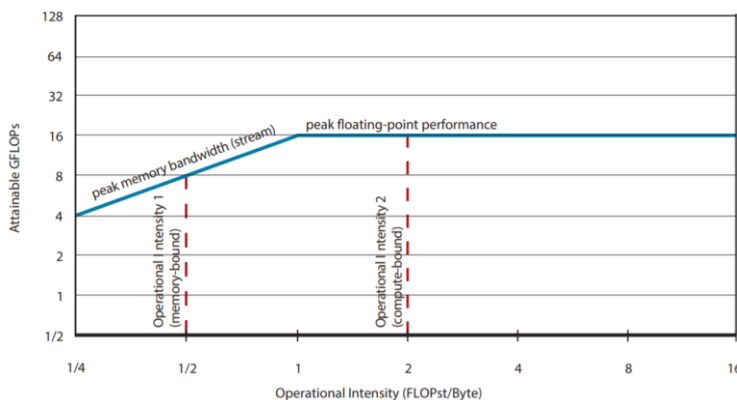
Se un kernel è **memory-bound**, ovvero quando il tempo affinché ci sia un output dal software è pregiudicato principalmente dalla velocità e dalla capacità della memoria, si ha:

$$AI < \frac{P_{peak}}{B_{peak}}$$

dove  $P_{peak}$  è il valore che indica la performance di picco, mentre  $B_{peak}$  è il valore che indica il picco del badwidth di memoria.

Mentre un kernel è **compute-bound** si ha che:

$$AI \geq \frac{P_{peak}}{B_{peak}}$$



## Specifiche JPDM2

Theoretical performance: 4612 GFLOP/s (device specs)

Theoretical Global Memory bandwidth: 224.32 GB/s (device specs)

## Calcolo Intensità aritmetica e applicazione del modello

Per calcolare l'Intensità aritmetica (AI) è possibile usare la seguente formula:

$$AI = FP / (TR + TW) * \text{tempo kernel (dal precedente passo)}$$

FP = floating point operations

TR/TW= dram read/write throughput

- Monolithic

```
==529589== Metric result:
Invocations
Device "GeForce GTX 980 (0)"
```


	Metric Name	Metric Description	Min	Max	Avg
Kernel: sciddicaResetFlows_Kernel(int, int, double, double*, int, int, int, int)					
1665	flop_count_dp	Floating Point Operations(Double Precision)	0	0	0
1665	dram_read_throughput	Device Memory Read Throughput	33.193MB/s	295.56MB/s	77.445MB/s
1665	dram_write_throughput	Device Memory Write Throughput	55.935GB/s	57.721GB/s	56.718GB/s
1665	dram_read_transactions	Device Memory Read Transactions	187	1660	435
1665	dram_write_transactions	Device Memory Write Transactions	323059	331039	326675

```
==529722== Metric result:
Invocations
Device "GeForce GTX 980 (0)"
```

	Metric Name	Metric Description	Min	Max	Avg
Kernel: sciddicaTFlowsComputation_Kernel(int, int, double, int*, int*, double*, double*, double*, double, double, int, int, int, int)					
1498	flop_count_dp	Floating Point Operations(Double Precision)	11458065	11479930	11472791
1498	dram_read_throughput	Device Memory Read Throughput	13.592GB/s	14.075GB/s	13.824GB/s
1498	dram_write_throughput	Device Memory Write Throughput	24.264GB/s	25.450GB/s	24.840GB/s
1498	dram_read_transactions	Device Memory Read Transactions	164764	168921	166744
1498	dram_write_transactions	Device Memory Write Transactions	294087	304326	299616




$AI = 11.472.791 / (13,82 + 24,84) * 1,32 = 391.725 \text{ [FLOP/byte]}$



```
==529890== Metric result:
Invocations
Device "GeForce GTX 980 (0)"
Kernel: sciddicaTWidthUpdate_Kernel(int, int, double, int*, int*, double*, double*, double*, int, int, int, int)
1665 flop_count_dp Floating Point Operations(Double Precision) 2402816 2402816 2402816
1665 dram_read_throughput Device Memory Read Throughput 46.881GB/s 52.040GB/s 49.422GB/s
1665 dram_write_throughput Device Memory Write Throughput 9.9767GB/s 11.154GB/s 10.591GB/s
1665 dram_read_transactions Device Memory Read Transactions 386623 412453 399941
1665 dram_write_transactions Device Memory Write Transactions 80345 89197 85708
```

$955,52 \text{ ms} = 0,95552 \text{ s}$

$AI = 2.402.816 / (49,42 + 10,59) * 0,956 = 38.278 \text{ [FLOP/byte]}$



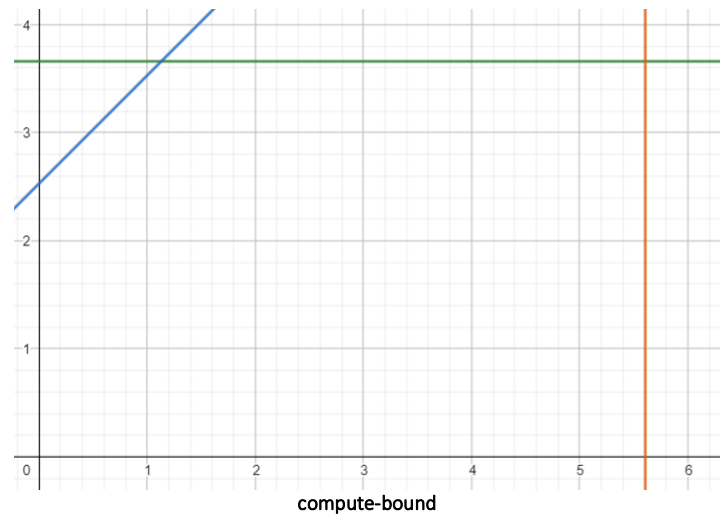
- Grid-Stride

```
==529394== Metric result:
Invocations
Device "GeForce GTX 980 (0)"
Kernel: sciddicaTResetFlows_Kernel(int, int, double, double*, int, int, int, int)
1665 flop_count_dp Floating Point Operations(Double Precision) 0 0 0
1665 dram_read_throughput Device Memory Read Throughput 33.676MB/s 303.64MB/s 77.837MB/s
1665 dram_write_throughput Device Memory Write Throughput 49.915GB/s 52.732GB/s 52.071GB/s
1665 dram_read_transactions Device Memory Read Transactions 191 1719 440
1665 dram_write_transactions Device Memory Write Transactions 288413 304456 301978
```

```
==530181== Metric result:
Invocations
Device "GeForce GTX 980 (0)"
Kernel: sciddicaTFlowsComputation_Kernel(int, int, double, int*, int*, double*, double*, double*, double, double, int, int, int, int)
1498 flop_count_dp Floating Point Operations(Double Precision) 11458065 11479930 11472791
1498 dram_read_throughput Device Memory Read Throughput 13.390GB/s 13.860GB/s 13.624GB/s
1498 dram_write_throughput Device Memory Write Throughput 23.876GB/s 24.893GB/s 24.401GB/s
1498 dram_read_transactions Device Memory Read Transactions 166169 171066 168493
1498 dram_write_transactions Device Memory Write Transactions 296060 306219 301790
```




$AI = 11.472.791 / (13,62 + 24,40) * 1,34 = 404.354 \text{ [FLOP/byte]}$



```
==530262== Metric result:
Invocations
Device "GeForce GTX 980 (0)"
Kernel: sciddicaTWidthUpdate_Kernel(int, int, double, int*, int*, double*, double*, double*, int, int, int, int)
1498      flop_count_dp      Floating Point Operations(Double Precision)      2402816      2402816      2402816
1498      dram_read_throughput      Device Memory Read Throughput      49.309GB/s      54.519GB/s      51.803GB/s
1498      dram_write_throughput      Device Memory Write Throughput      10.421GB/s      11.619GB/s      11.032GB/s
1498      dram_read_transactions      Device Memory Read Transactions      390361      415721      401415
1498      dram_write_transactions      Device Memory Write Transactions      80884      88486      85482
```

914,73 ms = 0,91473 s  
 $AI = 2.402.816 / (51,80 + 11,03) * 0,915 = 34.992 \text{ [FLOP/byte]}$




- Tiles without halo

```
==530414== Metric result:
Invocations
Device "GeForce GTX 980 (0)"
Kernel: sciddicaTResetFlows_Kernel(int, int, double, double*, int, int, int, int)
1665      flop_count_dp      Floating Point Operations(Double Precision)      0      0      0
1665      dram_read_throughput      Device Memory Read Throughput      32.568MB/s      291.27MB/s      76.009MB/s
1665      dram_write_throughput      Device Memory Write Throughput      56.703GB/s      58.123GB/s      57.358GB/s
1665      dram_read_transactions      Device Memory Read Transactions      185      1652      431
1665      dram_write_transactions      Device Memory Write Transactions      329769      338072      333482
```

```
==530443== Metric result:
```

Invocations	Metric Name	Metric Description	Min	Max	Avg
Device "GeForce GTX 980 (0)"					
Kernel: sciddicaTFlowsComputation_Kernel(int, int, double, int*, int*, double*, double*, double*, double, double, int, int, int, int)					
1498	flop_count_dp	Floating Point Operations(Double Precision)	13193885	13219010	13210859
1498	dram_read_throughput	Device Memory Read Throughput	12.501GB/s	12.870GB/s	12.661GB/s
1498	dram_write_throughput	Device Memory Write Throughput	23.251GB/s	24.443GB/s	23.859GB/s
1498	dram_read_transactions	Device Memory Read Transactions	165033	168542	166615
1498	dram_write_transactions	Device Memory Write Transactions	307811	319697	313976

AI = 13.210.859/(12,66 + 23,86) \* 1,43 = 517.293 [FLOP/byte]




```
==530468== Metric result:
```

Invocations	Metric Name	Metric Description	Min	Max	Avg
Device "GeForce GTX 980 (0)"					
Kernel: sciddicaTWidthUpdate_Kernel(int, int, double, int*, int*, double*, double*, double*, int, int, int, int)					
1665	flop_count_dp	Floating Point Operations(Double Precision)	2402816	2402816	2402816
1665	dram_read_throughput	Device Memory Read Throughput	61.593GB/s	63.865GB/s	62.681GB/s
1665	dram_write_throughput	Device Memory Write Throughput	12.559GB/s	13.649GB/s	13.143GB/s
1665	dram_read_transactions	Device Memory Read Transactions	385907	394579	390325
1665	dram_write_transactions	Device Memory Write Transactions	78009	85194	81846

697,92 ms = 0,69792 s

AI = 2.402.816/(62,68 + 13,14) \* 0,698 = 22.120 [FLOP/byte]



- Tiles with halo


```
==530579== Metric result:
```

Invocations	Metric Name	Metric Description	Min	Max	Avg
Device "GeForce GTX 980 (0)"					
Kernel: sciddicaTResetFlows_Kernel(int, int, double, double*, int, int, int, int)					
1665	flop_count_dp	Floating Point Operations(Double Precision)	0	0	0
1665	dram_read_throughput	Device Memory Read Throughput	33.402MB/s	292.37MB/s	75.623MB/s
1665	dram_write_throughput	Device Memory Write Throughput	58.486GB/s	61.715GB/s	60.637GB/s
1665	dram_read_transactions	Device Memory Read Transactions	191	1674	432
1665	dram_write_transactions	Device Memory Write Transactions	341835	360819	355064

```
==530607== Metric result:
```

Invocations	Metric Name	Metric Description	Min	Max	Avg
Device "GeForce GTX 980 (0)"					
Kernel: sciddicaTFlowsComputation_Kernel(int, int, double, int*, int*, double*, double*, double*, double, double, int, int, int, int)					
1498	flop_count_dp	Floating Point Operations(Double Precision)	13338623	13363748	13355597
1498	dram_read_throughput	Device Memory Read Throughput	20.192GB/s	20.591GB/s	20.389GB/s
1498	dram_write_throughput	Device Memory Write Throughput	31.791GB/s	32.305GB/s	32.027GB/s
1498	dram_read_transactions	Device Memory Read Transactions	353200	359500	356436
1498	dram_write_transactions	Device Memory Write Transactions	554741	563943	559910

AI =  $13.355.597 / (20,39 + 32,03) * 1,92 = 489.179$  [FLOP/byte]




```
==530639== Metric result:
```

Invocations	Metric Name	Metric Description	Min	Max	Avg
Device "GeForce GTX 980 (0)"					
Kernel: sciddicaTWidthUpdate_Kernel(int, int, double, int*, int*, double*, double*, double*, int, int, int, int)					
1665	flop_count_dp	Floating Point Operations(Double Precision)	2394008	2394008	2394008
1665	dram_read_throughput	Device Memory Read Throughput	47.288GB/s	48.941GB/s	48.048GB/s
1665	dram_write_throughput	Device Memory Write Throughput	10.535GB/s	11.295GB/s	10.924GB/s
1665	dram_read_transactions	Device Memory Read Transactions	374761	378932	376720
1665	dram_write_transactions	Device Memory Write Transactions	82595	88408	85650

884,10 ms = 0,8841 s

AI =  $2.394.008 / (48,05 + 10,92) * 0,884 = 35.888$  [FLOP/byte]



## 6. Conclusions

In questo report sono stati analizzati differenti algoritmi di parallelizzazione di SciddicaT in CUDA. Per raggiungere tale obiettivo ci si è serviti di: strumenti di profilazione di programmi CUDA (come *nvprof*),

modelli di performance visuali (come il Roofline Model) e varie misure di performance. La profilazione ha prodotto come output le rispettive statistiche (tempi di esecuzione CPU/GPU, tempi massimi, minimi, ecc.) degli algoritmi e con le opportune opzioni del comando nvprof ha fornito alcune metriche utili alla costruzione del modello Roofline mentre i plot hanno permesso l'analisi anche dal punto di vista grafico. Il Roofline ha fornito informazioni riguardanti la natura dei kernel, e quindi l'appartenenza alla famiglia dei "compute-bound" o dei "memory-bound".